

Kapitel 1 - Das einfache lineare Regressionsmodell

Einfaches lineares Regressionsmodell

Das einfache lineare Regressionsmodell hat die Form

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

für ein festes numerisches x_i und $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$. Beachte, dass per Definition gilt $Y_i | x_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$

Kleinste Quadrate (KQ) Schätzer

Wir schätzen die Parameter (β_0, β_1) durch

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{(\beta_0, \beta_1)} \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 x_i))^2 \quad (1)$$

und nennen $(\hat{\beta}_0, \hat{\beta}_1)$ den KQ-Schätzer von (β_0, β_1) und $\hat{\varepsilon}_i := Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$ die Residuen.

Existenz und Berechnung vom KQ Schätzer

Der KQ-Schätzer existiert und ist eindeutig, falls $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$. Dieser lässt sich berechnen als

$$\hat{\beta}_1 = \frac{S_{xy}}{S_x^2} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

Durch differenzieren von der Gleichung (1) erhält man $(\hat{\beta}_0, \hat{\beta}_1)$ als Lösung der Normalgleichungen

$$\sum_{i=1}^n \hat{\varepsilon}_i = 0$$

$$\sum_{i=1}^n \hat{\varepsilon}_i x_i = 0$$

Interpretation der Modellparameter

Für $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, $i = 1, \dots, n$ mit $\mathbb{E}(Y_i | x_i) = \beta_0 + \beta_1 x_i$ gilt,

- wenn x um eine **Einheit** steigt, dann steigt Y im Erwartungswert um β_1 Einheiten.
- Es gilt $\beta_0 = \mathbb{E}(Y | X = 0)$.
- Der Parameter σ die erwartete Abweichung der

Eigenschaften des KQ-Schätzers

Gegeben dem einfachen linearen Modell, gilt für den KQ-Schätzer $(\hat{\beta}_0, \hat{\beta}_1)$

- Erwartungstreue: $\mathbb{E}(\hat{\beta}_0, \hat{\beta}_1) = (\beta_0, \beta_1)$.
- $V(\hat{\beta}_1) = \frac{\sigma^2}{n S_x^2}$ und $V(\hat{\beta}_0) = \sigma^2 (\frac{1}{n} + \frac{\bar{x}^2}{n S_x^2})$.
- $(\hat{\beta}_0, \hat{\beta}_1)$ ist der maximum-likelihood Schätzer.

Schätzer für σ^2

Gegeben dem einfachen linearen Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, gilt

$$\hat{\sigma}^2 = \frac{RSS}{n-2}$$

$$\hat{\sigma}^2 := \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

ist ein erwartungstreuer Schätzer von σ^2 und

$$\frac{RSS}{\sigma^2} = \frac{n-2}{\sigma^2} \hat{\sigma}^2 \sim \chi_{n-2}^2$$

Der KQ-Schätzer $(\hat{\beta}_0, \hat{\beta}_1)$ und der Schätzer $\hat{\sigma}^2$ sind stoch.unabhängig.

Konfidenzintervalle für β_0 und β_1

Gegeben dem einfachen linearen Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, gilt für $\hat{\beta}_1$ und $\hat{\beta}_0$

$$\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_1} := \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

$$\frac{\hat{\beta}_0 - \beta_0}{\hat{\sigma}_{\hat{\beta}_0}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_0} := \sqrt{\hat{\sigma}^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}}$$

Damit können wir Konfidenzintervalle zum Niveau $1 - \alpha$ für β_1 und β_0 erzeugen:

$$[\hat{\beta}_1 - \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2); \hat{\beta}_1 + \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2)]$$

$$[\hat{\beta}_0 - \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2); \hat{\beta}_0 + \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2)]$$

Varianz von Prognosefehler = $\text{Var}((\hat{\beta}_0 + \hat{\beta}_1 x_{n+1}) - (\beta_0 + \beta_1 x_{n+1})) + \text{Var}(\varepsilon_{n+1})$

= $\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_{n+1}) + \sigma^2$

mit $\text{Var}(\hat{\eta}_{n+1}) = \text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_{n+1}) = \text{Var}(\hat{\beta}_0) + x_{n+1}^2 \text{Var}(\hat{\beta}_1) + 2 x_{n+1} \text{Cov}(\hat{\beta}_0, \hat{\beta}_1)$

u. $\text{Var}(\hat{\beta}_0) = \sigma^2 (\frac{1}{n} + \frac{\bar{x}^2}{n S_x^2})$, $\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{n S_x^2}$, $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{n S_x^2}$

Prognosefehler: $\hat{\eta}_{n+1} - \eta_{n+1} = [\hat{\beta}_0 + \hat{\beta}_1 x_{n+1} - \beta_0 - \beta_1 x_{n+1}] - \varepsilon_{n+1}$

Quadratsummenzerlegung

Gegeben sei ein einfaches lineares Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ und $\hat{Y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i$. Dann gilt

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{SSE}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{SSM}}$$

SST(otal): Gesamtstreuung von Y
SSE(rror): Streuung der Residuen
SSM(odel): Streuung, die das Modell erklärt

Bestimmtheitsmaß

Unter Verwendung der obigen Notation definieren wir das Bestimmtheitsmaß als

$$R^2 = \frac{\text{SSM}}{\text{SST}} = 1 - \frac{\text{SSE}}{\text{SST}}$$

Es gilt

$$R^2 = r_{xy}^2 = \frac{S_{xy}}{S_x S_y}$$

wobei r_{xy} der Bravais-Pearson Korrel.koeffizient ist.

Interpretation von R^2

- R^2 beschreibt den Anteil der Varianz von Y , die durch x erklärt wird.
- R ist invariant gegenüber linearen linearen Transformationen von x und Y (weil r_{xy} invariant)
- R ist symmetrisch bzgl. x und Y .
- R^2 hängt auch von der Streuung von x in der Stichprobe ab.

Prognosewert

Gegeben sei ein einfaches lineares Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ und $\hat{Y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i$, $i = 1, \dots, n$. Sei nun eine weitere Beobachtung x_{n+1} mit zugehörigem $Y_{n+1} = \beta_0 + \beta_1 x_{n+1} + \varepsilon_{n+1}$ gegeben. Der Prognosewert von Y_{n+1} ist definiert als $\hat{Y}_{n+1} = \hat{\beta}_0 + \hat{\beta}_1 x_{n+1}$

Prognosefehler

Gegeben sei ein einfaches lineares Modell, sowie eine weitere Beobachtung x_{n+1} mit zugehörigem Y_{n+1} sowie der Prognosewert \hat{Y}_{n+1} . Dann gilt

$$E(\hat{Y}_{n+1} - Y_{n+1}) = 0$$

$$V(\hat{Y}_{n+1} - Y_{n+1}) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

\hat{Y}_{n+1} unabh. von Schätzung (β_0, β_1) $V(\hat{Y}_{n+1}) = \sigma^2 \left[\frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]$, $V(\varepsilon_{n+1}) = \sigma^2$

Prognoseintervall

Gegeben sei ein einfaches lineares Modell, sowie eine weitere Beobachtung x_{n+1} mit zugehörigem Y_{n+1} sowie der Prognosewert \hat{Y}_{n+1} . Dann können wir für Y_{n+1} ein Konfidenzintervall zum Niveau $1 - \alpha$ konstruieren:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2)]$$

mit

$$\hat{\sigma}_{\hat{Y}_{n+1}} = \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

unbekanntes σ^2 schätzen

R-Code

```
# simuliere aus einfachem lin. Modell
beta0 <- 3
beta1 <- 1
sigma <- 2
x <- seq(from = 0, to = 10, by = 0.5)
e <- rnorm(length(x), sd = sigma)
y <- beta0 + beta1 * x + e
dat <- data.frame(x, y)
```

```
# Lineares Modell erzeugen
reg = lm(y ~ x, data = dat)
summary(reg)
```

```
# Konfidenzintervalle
confint(reg, level = 0.95)
```

Interpretation von transformierten Modellen

- Log-Log-Modell: $\log(Y_i) = \beta_0 + \beta_1 \log(x_i) + \varepsilon_i$
 \Rightarrow Y_i steigt im EW um e^{β_1} bei 10% x_i

$$\log(Y_i) = \beta_0 + \beta_1 \log(x_i) + \varepsilon_i$$

Wenn x_i um den Faktor a steigt, dann steigt Y_i im Erwartungswert um den Faktor $a^{\beta_1} = e^{\beta_1 \log(a)}$.
 $e^{\beta_1 \log(1.01)} = e^{\log(1.01) \beta_1} = 1.01^{\beta_1}$ *genau bei 10%!*

Alternativ: Wenn x_i um 1% steigt, dann steigt Y_i im Erwartungswert um $100 \cdot (e^{\beta_1 \log(1.01)} - 1)\%$.

- Linear-Log-Modell:

$$Y_i = \beta_0 + \beta_1 \log(x_i) + \varepsilon_i$$

Wenn x_i um $p\%$ steigt, dann steigt Y_i im Erwartungswert um $\beta_1 \cdot \log(1 + p\%)$.

Alternativ: Wenn x_i um 1% steigt, dann steigt Y_i im Erwartungswert um approximativ $\beta_1\%$ Einheiten.

- Log-Linear-Modell:

$$\log(Y_i) = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Wenn x_i um eine Einheit steigt, dann steigt Y_i im Erwartungswert um den Faktor e^{β_1} .

Anmerkungen aus der Vorlesung

R^2 ist abhängig von X . Das heißt über mehrere Studien hinweg, die das gleiche messen, ist R^2 nur vergleichbar, wenn auch X vergleichbar ist. Je sicherer wir mit unserem Schätzer sein wollen, desto höher sollten wir die Varianz von X einstellen. Gegeben, dass der Zusammenhang tatsächlich linear ist, würde eine höhere Varianz von X zu einer geringeren Varianz von $\hat{\beta}_1$ führen (also $\text{Var}(X) \uparrow$ doppelt gut)

Im multiplen Reg.modell ist es KEINE Annahme, dass x_i, x_j unabhängig voneinander sind. Es wäre nur praktisch für die Interpretation der Effekte. Das "magische" am multiplen Reg.modell ist, dass ich für verschiedene Größen kontrollieren/korrigieren kann.

Annahmen des linearen Regressionsmodells

Gegeben sei das einfache (oder multiple) lineare Regressionsmodell mit

$$Y = X\beta + \varepsilon \quad (1)$$

$$E(\varepsilon) = 0 \quad (2)$$

$$V(\varepsilon_i) = \sigma^2, \text{ für alle } i = 1, \dots, n \quad (3)$$

$$\varepsilon_i \text{ sind paarweise unabhängig voneinander} \quad (4)$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2), \text{ für alle } i = 1, \dots, n \quad (5)$$

Die folgende Tabelle gibt an, welche Annahmen für die jeweiligen Schätzer, Eigenschaften, Größen etc. benötigt werden.

	(1)	(2)	(3)	(4)	(5)
KQ-Schätzer	✓				
ML-Schätzer	✓	✓	✓	✓	✓
$E(\hat{\beta}) = \beta$	✓	✓			
$\hat{\beta} \sim \mathcal{N}(\beta, V(\hat{\beta}))$	✓	✓	✓	✓	(✓)
Konfidenzintervalle	✓	✓	✓	✓	(✓)
Prädiktionsintervalle	✓	✓	✓	✓	✓

(✓) bedeutet, dass die Annahme nicht benötigt wird, wenn der Stichprobenumfang n groß genug ist.

Beachte: Grundsätzlich gelten alle Aussagen nur unter der zentralen Modellannahme des linearen Zusammenhangs von $E(Y)$ und X !