

Herleitungen im multiplen linearen Modell

$$y = XB + \varepsilon$$

Skalarprodukt der Fehlervektoren $\hat{=} \|y - XB\|^2$

$$KQ\text{-Schätzer: Minimiere } \hat{\varepsilon}^T \hat{\varepsilon} = (y - XB)^T (y - XB) = y^T y - y^T X B - (XB)^T y + (XB)^T X B = y^T y - y^T X B - \underbrace{y^T X B - (y^T X B)^T}_{\text{Skalar}} + B^T X^T X B$$

$$\hat{\beta} = \arg \min_B (y - XB)^T (y - XB)$$

$$\frac{\partial}{\partial B} (y - XB)^T (y - XB) = 2B^T y - 2B^T X^T X B$$

$$\text{Ableiten nach } B: \frac{\partial \hat{\varepsilon}^T \hat{\varepsilon}}{\partial B} = -2X^T y + 2X^T X B \stackrel{!}{=} 0$$

$$\Leftrightarrow X^T X B = X^T y \Leftrightarrow \hat{\beta} = (X^T X)^{-1} X^T y \Rightarrow \hat{y} = X \hat{\beta} = X (X^T X)^{-1} X^T y = P y$$

hat Matrix P

$$KQ\text{-Schätzer erfüllt Normalgleichungen } X^T (y - X \hat{\beta}) = X^T \hat{\varepsilon} = 0$$

$$\hat{\varepsilon} = y - \hat{y} = (I - P) y = Q y, \quad (I - P)^T \hat{\varepsilon} = Q^T \hat{\varepsilon}$$

$$\text{Residual Matrix } Q = I - P, \quad y = XB + \varepsilon, \quad (I - P)(XB + \varepsilon)$$

$$\text{wobei: } (I - P)XB = 0 \text{ weil } P(XB) = XB$$

KQ-Schätzer ist erwartungstreu: $E(\hat{\beta}) = \beta$

X nicht zufällig

$$E(\varepsilon) = 0, \quad X \text{ konstant}$$

$$E(B) = \beta$$

$$E(\hat{\beta}) = E((X^T X)^{-1} X^T y) = (X^T X)^{-1} X^T E(y) = (X^T X)^{-1} X^T E(XB + \varepsilon) = (X^T X)^{-1} X^T X E(B) = (X^T X)^{-1} X^T X \beta = \beta$$

$$E(B) = \beta$$

$$\text{Var}(y) = \text{Var}(\varepsilon) = \sigma^2 I$$

$$\text{Varianz des KQ-Schätzers: } W(\hat{\beta}) = W((X^T X)^{-1} X^T \text{Var}(y) (X^T X)^{-1})^T = (X^T X)^{-1} X^T \text{Var}(y) X (X^T X)^{-1} = (X^T X)^{-1} X^T \cdot \sigma^2 I \cdot X (X^T X)^{-1}$$

mehrere Parameter \Rightarrow Kov. matrix

$$\text{Var}(B y) = B \text{Var}(y) B^T = X (X^T X)^{-1} X^T \cdot \sigma^2 I \cdot X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

homoskedastizität & unkorrelierte Fehler

$$\text{Wenn } \varepsilon \sim N(0, \sigma^2 I) \text{ erfüllt ist } \Rightarrow \hat{\beta} \text{ ist normalverteilt als lineare Transf. einer normalverteilten } ZV \varepsilon, \quad \hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

$$\hat{\varepsilon} = (I - P) \varepsilon$$

$$\text{Beweis: } \hat{\beta} = (X^T X)^{-1} X^T y = (X^T X)^{-1} X^T (XB + \varepsilon) = (X^T X)^{-1} X^T X B + (X^T X)^{-1} X^T \varepsilon = B + (X^T X)^{-1} X^T \varepsilon = \hat{\beta} \text{ abh. von } \varepsilon \text{ aber unabh. von } \hat{\varepsilon}$$

$$y = XB + \varepsilon$$

$$Z_p$$

$$\text{also } \hat{\beta} \text{ ist affin-lineare Transformation des Fehlervektors } \varepsilon$$

ε folgt multivariater $NV \Rightarrow \hat{\beta}$ als lineare Transf. dieser multivariaten NV ist selbst normalverteilt!

$$\text{Es gilt: } \hat{\beta} \perp \hat{\varepsilon}^2$$

$$\text{erfordert } \varepsilon \sim N(0, \sigma^2 I)$$

σ^2 kann man auch als fixen unbekannten Parameter σ^2 interpretieren

$$\text{Erwartungstreue Schätzung von } \sigma^2: \hat{\sigma}^2 = \frac{1}{n - (p+1)} \hat{\varepsilon}^T \hat{\varepsilon} = \frac{1}{n - (p+1)} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

$$\text{Verteilung: } \hat{\sigma}^2 \sim \chi^2(n - p)$$

erfordert alle Modellannahmen bis auf NV von ε

$\hat{\varepsilon}^2$ - Grade-Korrektur: bereits $(p+1)$ Parameter geschätzt

Exkurs: Maximum Likelihood

$$\text{Unter Annahme } y \sim N(XB, \sigma^2) \text{ ist } f(y) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} (y - XB)^T (y - XB)\right) \Rightarrow \max_{\beta} f(y) = \max_{\beta} \left(-\frac{1}{2\sigma^2} (y - XB)^T (y - XB)\right)$$

$$\hat{\beta}_{MLE} = (X^T X)^{-1} X^T y$$

$$\text{identisch zu KQ-Schätzer}$$

$$\Rightarrow \log\text{-Likelihood } \log L := \ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (y - XB)^T (y - XB)$$

(haten σ^2 fest)

$$\text{MLE für } \beta: \frac{\partial \ell}{\partial \beta} = -\frac{1}{2\sigma^2} \cdot 2 \cdot (-X^T) (y - XB) = \frac{1}{\sigma^2} X^T (y - XB) \stackrel{!}{=} 0 \Rightarrow X^T X B - X^T y \Leftrightarrow \hat{\beta}_{MLE} = (X^T X)^{-1} X^T y$$

↓

$$\text{Verteilte MLE-Schätzung für } \sigma^2: \frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2} \cdot \frac{1}{\sigma^4} \hat{\varepsilon}^T \hat{\varepsilon} \stackrel{!}{=} 0 \Rightarrow -n\sigma^2 + \hat{\varepsilon}^T \hat{\varepsilon} = 0 \Leftrightarrow \hat{\sigma}^2_{MLE}(\beta) = \frac{1}{n} (y - X \hat{\beta})^T (y - X \hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Effektplots: Isolierung von individuellen Effekten einzelner Regressoren, siehe Ex-02_well

\rightarrow geht auch für Prognose: Entsprechend $X_{n+1:n+j}$ Effekte auf y_{n+1} mit zugehörigen Konfidenzintervallen

a) Konfidenziale Darstellung: Meist Betrachtung von $E(y_i | X_{i1}, \dots, X_{ip})$ für verschiedene Werte von X_{ij} der interessierenden Kovariablen j

unter MW der anderen Einflussgrößen (folgenden konstant gehalten) \rightarrow reale Zahlen in Designmatrix $\tilde{X}_i = (\tilde{X}_{i1}, \dots, \tilde{X}_{ip})$

Unsicherheit der Schätzung $\hat{\beta}$ dann geg. durch $\hat{\beta}_j \pm \hat{\sigma}_{\hat{\beta}_j}$ also $\hat{\beta}_j$ ist t -verteilt

Steigung im Plot ist exakte β_j , andere Modellkoeff. (Intercept, weitere Kovariablen) verschieben nur Lage

Im multiplen Modell ohne non-lineare X -Terme u. ohne Interaktionen ist konf. Effektplot im Prinzip nur grafische Darstellung des Reg. lcof. in 2D

Bei Interaktionstermen und/oder Polynomen 3. Grades zeigt Effektplot mehr, und zwar modelltheoretische (potenzielle komplexe) Beziehung zwischen isolierter X -Variable und y

b) Kontrast-Darstellung: Idee \rightarrow Wie ändert sich \hat{y}_i , wenn sich X_{ij} in Bezug zu Referenzwert der isolierten Kovariablen X_j (meist $MW(X)$) ändert?

$$\hat{y}_i - y_i^* = \beta_0 + \beta_1 X_{i1} + \dots + \beta_j X_{ij} + \dots + \beta_p X_{ip} - (\beta_0 + \beta_1 X_{i1}^* + \dots + \beta_j X_{ij}^* + \dots + \beta_p X_{ip}^*) = (X_{ij} - X_{ij}^*) \beta_j$$

$$\text{Unsicherheit der Schätzung ergibt sich durch } \text{Var}(\hat{y}_i - y_i^*) = \text{Var}((X_{ij} - X_{ij}^*) \beta_j) = (X_{ij} - X_{ij}^*)^2 \text{Var}(\beta_j)$$

Eng verknüpft mit Analyse von bedingten Mittelwerten bei diskontinuierlichen Einflussgrößen \rightarrow gestrichelter MW von Gruppe B bedingt auf MW von Referenzgruppe A

Konfidenzintervall Effektplot ermöglicht isolierte Betrachtung e. einzelnen Kovariablen X_j (bedingte) bei Unsicherheitsschätzung allerings nur Schätzung v. β_j

Im simplen linearen Modell sind beide Methoden nur mathematisch unterschiedliche Repräsentationen desselben linearen Zusammenhangs.

Konfidenzintervall Effektplot ist besser wenn wir untersuchen wollen, wie sich Outcome über Range von Prädiktor hinweg verändert.

Konfidenzintervall für Parameter β_k

→ nicht deutlich, dass Intervall zentral auf sample-Bias und Koeffizient fix !!
 Schätztest formuliert: Konf. Intervall überdeckt in $(1-\alpha)\%$ der Fälle den wahren Parameter

β -Vektor ist normalverteilt $\hat{\beta} \sim N_p(\beta, \sigma^2(X^T X)^{-1})$

Beachte, dass $\hat{\beta}$ und $\hat{\sigma}^2$ unabhängig sind

Einzelne Koeffizienten β_k jedoch t -Verteilt: $\frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2 \hat{v}_{kk}}} \sim t(n-p, 0)$

Hypothese: wahres β_k innerhalb von Konf. Intervall um unseren Schätzer $\hat{\beta}_k$

Diagonalentries in geschätzter Kovarianzmatrix von $\hat{\beta}$

in $(1-\alpha)\%$ der Fälle liegt wahres β_k innerhalb von Konf. Intervall um unseren Schätzer $\hat{\beta}_k$

Wenn $0 \in$ Intervall, so kann man $\beta_k = 0$ nicht ausschließen

Konfidenzintervall zum $MW_{n-1-\alpha} = 1-\alpha: [\hat{\beta}_k - \hat{\sigma} \hat{v}_{kk} t_{1-\alpha/2}(n-p), \hat{\beta}_k + \hat{\sigma} \hat{v}_{kk} t_{1-\alpha/2}(n-p)]$

→ nicht signifikant! $t_{1-\alpha/2} \neq$ Rand W. lin.

Darauf basierend zweiseitiger t -Test auf $P(=1)$ siehe R-Output, für Signifikanz $P \leq \alpha$ gewant



Testwert $\frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2 \hat{v}_{kk}}} \leq 0$ (also $\beta_k = 0$) zum Niveau $1-\alpha$

Wenn t -Wert mit Wert $\leq \alpha$, auf demselben Wert, so ist β_k bzw. Effekt von Kovariante signifikant zum $MW_{n-1-\alpha}$ Einplayen 95%]

Interpretation: in $(1-\alpha)\%$ der Fälle liegt geschätzte Formel / Lernreihe innerhalb der Konfidenzbracket

Darüber hinaus gibt es auch Konfidenzintervall für wahre Regressionsgerade (bzw. wahre Modellannahme oder nur in 2D-Modell, grafisch sinnvoll zu interpretieren)

Konfidenzbracket: Wollen EW einfügen $E(y_i | x_i) = \hat{y}_i = \beta_0 + \beta_1 x_i$ $[\hat{y}_i - \sqrt{\text{Var}(\hat{y}_i)} t_{1-\alpha/2}(n-p), \hat{y}_i + \sqrt{\text{Var}(\hat{y}_i)} t_{1-\alpha/2}(n-p)]$ mit $W(\hat{y}_i) = W(\beta_0 + \beta_1 x_i)$

Beachtungen nur Streuung durch Parameter β_0, \dots, β_p (hierin Unsicherheit bzw. Varianz)

2D: Oberer Grenze für $E(y_i)$ wird für alle β_k gebildet, lokal symmetrisch um \hat{y}_i , aber nicht überall gleichbreit: Tücherförmig

quasi Konfidenzintervall für neue Beobachtung, neue Zeilen $X_{n+1}^T \rightarrow y_{n+1}$ $X_{n+1}^T = (1, x_{n+1,1}, \dots, x_{n+1,p})$

Proaktionsintervalle zu $MW_{n-1-\alpha}: [\hat{y}_{n+1} - \hat{\sigma} \hat{v}_{n+1,1} t_{1-\alpha/2}(n-p), \hat{y}_{n+1} + \hat{\sigma} \hat{v}_{n+1,1} t_{1-\alpha/2}(n-p)]$

Es gilt $E(\hat{y}_{n+1} - y_{n+1}) = 0$ mit Prognosefehler $\text{Var}(\hat{y}_{n+1} - y_{n+1}) = \sigma^2 (1 + \frac{1}{n} + \frac{(x_{n+1,1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}) = \text{Var}(\hat{\epsilon}_{n+1}) + \text{Var}(\hat{y}_{n+1})$

$E(\hat{y}_{n+1} - y_{n+1}) = x_{n+1}^T E(\hat{\beta}) - E(\epsilon_{n+1}) = 0$ allgemein: $\text{Var}(\hat{y}_{n+1} - y_{n+1}) = \text{Var}(x_{n+1}^T \hat{\beta} - x_{n+1} \beta)$

→ deutlich breiter als Konfidenzbracket, weil zusätzlich Streuung von ϵ_{n+1} berücksichtigt wird

* Also Symmetrie fällt ganz weg, wenn wir statt Verteilungsskizze mit t -Verteilung der Parameter mit bootstrapping arbeiten

Verteilung schätzen mit Verteilung von Sample

Gauss-Markov-Theorem: $y = X\beta + \epsilon$ mit $\text{rank}(X) = p$

$E(\epsilon) = 0, V(\epsilon) = \sigma^2 I$ also Homoskedastizität & unkorrelierte Fehler

\Rightarrow unter allen erwartungsstreuen linearen Schätzern ist KQ-Schätzer derjenige mit der kleinsten Varianz

BUE-Schätzer $\hat{\beta}$ ist linear und biased estimator

Also: für jeden anderen unbiasierten linearen Schätzer $\tilde{\beta}$ gilt $\text{Var}(\tilde{\beta}) > \text{Var}(\hat{\beta}) \Leftrightarrow \text{Var}(\tilde{\beta}) = \text{Var}(\hat{\beta}) + M, M$ positiv semidefinit

Was machen wir, wenn Fehler nicht normalverteilt, sondern nur homoskedastisch mit exakter Varianz $\sigma^2 I$?

Konsistenz des KQ-Schätzers Betrachten Modell mit steigendem Stichprobenumfang n

X_n : Designmatrix der ersten n Beobachtungen, Folge X_n

$\hat{\beta}(n)$: KQ-Schätzer aus diesen n -Beobachtungen

Voraussetzung: X_n hat vollen Rang für alle $n > p$ sodass $X_n^T X_n$ immer invertierbar

$\lim_{n \rightarrow \infty} (\lim_{n \rightarrow \infty} \frac{1}{n} X_n^T X_n - V) = 0$ "Information in den Daten wächst mit n "

$\lim_{n \rightarrow \infty} (X_n^T X_n)^{-1} = 0$ "Information in den Daten wächst mit n "

$\hat{\beta}(n) \xrightarrow{P} \beta$ asymptotisch ist Erwartungsstreuung, mit $n \rightarrow \infty$ geht Bias gegen 0

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt

$\hat{\beta}(n) \xrightarrow{f.s.} \beta$ falls zudem ϵ_i identisch verteilt