

Test von linearen Hypothesen

Altles

Exkurs: Non-lineare Hypothesen lassen sich relativ einfach bayesisch überprüfen

$q \neq$ Anzahl linear unabh. Zeilen in A

Lineare Hypothese im multiplen Modell: $A\beta = c$ mit $A \in \mathbb{R}^{a \times (p+1)}$, $c \in \mathbb{R}^a$ und $\text{rank}(A) = a$ a : Anzahl der überprüften Hypothesen

Herleitung der Teststatistik: Lösen Minimierungsproblem $\min_{\beta} \|y - X\beta\|^2$ unter Nebenbedingung $A\beta = c$ mithilfe von Lagrange-Methode

$$\Rightarrow \hat{\beta} = \beta - (X^T X)^{-1} A^T (A^T (X^T X)^{-1} A^T)^{-1} (A\hat{\beta} - c) = \hat{\beta} - w$$

$= w$

Fehlerquadratsumme unter linearer Hypothese $A\beta = c$: $\hat{\beta} = y - \hat{y} = y - X\hat{\beta} = y - (X\hat{\beta} - Xw) = (y - X\hat{\beta}) + Xw = \hat{\epsilon} + Xw$

$$SSE(H_0) = \sum \hat{\epsilon}^2 = (\hat{\epsilon} + Xw)^T (\hat{\epsilon} + Xw) = \sum \hat{\epsilon}^2 + 2w^T X^T \hat{\epsilon} + w^T X^T X w = \dots = \sum \hat{\epsilon}^2 + (A\hat{\beta} - c)^T (A(X^T X)^{-1} A^T)^{-1} (A\hat{\beta} - c)$$

$\hat{\epsilon}^T X w = (X^T \hat{\epsilon})^T w$

Differenz der Fehlerquadratsumme von Originalmodell und Modell unter linearer Hypothese H_0 :

$$SSH = SSE(H_0) - SSE = \sum \hat{\epsilon}^2 - \sum \hat{\epsilon}^2 = (A\hat{\beta} - c)^T (A(X^T X)^{-1} A^T)^{-1} (A\hat{\beta} - c)$$

$$\text{Wobei } \text{Var}(A\hat{\beta} - c) = \sigma^2 A (X^T X)^{-1} A^T$$

$$\text{Verteilung der normierten Quadratsummen: } \frac{SSH}{\sigma^2} \sim \chi_a^2, \quad \frac{SSE}{\sigma^2} = \frac{\sum \hat{\epsilon}^2}{\sigma^2} = \frac{y^T y - y^T \hat{y}}{\sigma^2} = \frac{\sum \hat{\epsilon}^2}{\sigma^2} \sim \chi_{n-p}^2$$

$(\hat{\epsilon} = y - \hat{y})$ $(\hat{\epsilon}^2 = \sum \hat{\epsilon}^2)$ $(n-p)$

Da $\hat{\sigma}^2$ und $\hat{\beta}$ gemäß Modellannahmen voneinander unabh. sind, gilt $TF = \frac{SSH/a}{SSE/(n-p)} = \frac{SSH/a}{MSE} \sim F(a, n-p)$ zentrale F -Verteilung mit $TF \sim F(a, n-p)$

\Rightarrow Testentscheidung: lineare Hypothese H_0 wird abgelehnt, wenn $TF > F_{1-\alpha}(a, n-p)$ rechtsseitiger F -Test

Nullhypothese wird abgelehnt, wenn relativer Unterschied zwischen SSE und $SSE(H_0)$ ausreichend groß ist in R schnell: $\text{anova}(\text{modell_rech}, \text{modell_full})$
 \hookrightarrow Falls ja, dann führt unreguliertes Modell zu signifikanter Reduktion des $SSE \Rightarrow$ Alternativ-Hypothese signifikant

($\beta_0 = 0$ -testen mittels Intercept ist "verschobener" totales Modell durch Zero-Intercept)

Spezialfall Overall-Test $H_0: \beta_1 = \dots = \beta_p = 0$ in allgemeiner Form: $A\beta = \vec{0}$ mit $A = \begin{pmatrix} 0 & 1 & 0 & \dots & 0 \end{pmatrix}$

Tester, ob Modell irgendwas taugt oder komplett random (Nullhypothese) \Leftrightarrow Test auf $R^2 = 0$ 1. Spalte Nuller wegen Intercept

Wenn $\bar{F}_0 = \frac{MSM}{MSE} > F_{1-\alpha}(p, n-p)$ lehnen wir H_0 ab \Rightarrow $H_1: \exists \beta_k \neq 0$ wird auf diesem Niveau angenommen ($\hat{\beta}$ Wert)
 $(\hookrightarrow$ Nullhypoth. $\beta_k = 0$) isolierter Test auf $\beta_k = 0$: Teilweise F -Hypothesentest äquiv. zu Unstet. t -Test

Unterschied zu einzelnen t -Tests auf $\beta_k = 0$ für alle k nacheinander: F -Test berücksichtigt mögliche Korrelation zwischen KO-koef. β_1, \dots, β_p
 Es kann sein, dass alle individuell nicht sign. $\neq 0$ aber zusammengekommen schon, z.B. bei starker Multikollinearität
 oder einzeln sign. $\neq 0$ aber gemeinsam mit anderer Kovariate (F -Test auf $\beta_k = 0$) nicht signifikant

Übung 3 Übung 7 $p=6$ Bestimme Matrix A für Hypothese: $\beta_0 = 0, \beta_2 = 0, \beta_1 = \beta_3, \beta_4 - \beta_2 = 1, \beta_4 = 2$

$$\begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}$$

Übung 3 Übung 7 Lineares Modell, $p=6$ (eine Fehler-Variante geschaltet)

$$H_0: \beta_1 = \dots = \beta_6 = 0$$

a) Überprüfung, ob mindestens eine der Kovariate Zusammenhang mit Zielvariable \Rightarrow Overall F -Test

$$TF \sim F(6, n-7)$$

$$H_0: \beta_0 = 0$$

$$H_0: \beta_0 = 0 \Rightarrow A = \begin{pmatrix} 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix}, \beta = \text{siehe oben}, c = 0$$

b) Teste ob zweifler Kovariante Zusammenhang mit Zielgröße aufweist $\Rightarrow A = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix}, \beta = \text{siehe oben}, c = 0$

$$TF \sim F(1, n-7)$$

c) Teste, ob Zielgröße von erster oder vierter Kovariate linear abhängt $\Rightarrow A = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}, c = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

$$TF \sim F(2, n-7)$$

d) Teste, ob fünfte und sechste Kovariate selben Zusammenhang mit Zielvar haben $\Rightarrow A = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 1 & -1 \end{pmatrix}, c = 0$

$$TF \sim F(1, n-7)$$

Beachte: geschaltetes Modell definiert als $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 (x_{i5} + x_{i6})$ in R : $\text{lm}(y \sim y_1 + \dots + I(y_5 + y_6))$

(alle x_{ij})

e) Teste, ob sich Z -Score mit einem Firsting des Kinderalters um eine Einh. (Monat) um zwei Punkte verringert $\Rightarrow H_0: \beta_3 = -2$

$$TF \sim F(1, n-7)$$

Restingwertes Modell: $\dots - 2 \times \text{age} + \dots$ oder in R : $\text{lm}(y \sim y_1 + y_2 + \text{age}[-2 \times y_3] + \dots)$ z.B. für anova $A = \begin{pmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{pmatrix}, c = -2$