

Kapitel 2 - Das multiple lineare Regressionsmodell

Multiples lineares Regressionsmodell

Das multiple lineare Regressionsmodell hat die Form

$$Y_i = \underbrace{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}}_{x_i^T \beta} + \varepsilon_i; i = 1, \dots, n$$

oder in Matrix-Vektor Notation: $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ mit

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{pmatrix} \text{ Designmatrix}$$

$$\beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix}, \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}. \text{ Var}(\varepsilon) = \text{Var}(\mathbf{Y}) = \begin{pmatrix} \sigma^2 & & \\ & \ddots & \\ & & \sigma^2 \end{pmatrix} \sigma^2 \cdot \mathbf{I}$$

\hookrightarrow Homosked. und unkorrelierte Fehler

Wir nehmen dabei an, dass $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$ eine feste Design-Matrix mit vollem Rang ist und dass $\varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$. Wir definieren $p' := p + 1$. $= \text{rank } \text{rg}(\mathbf{X})$

Kleinste Quadrate (KQ) Schätzer

Wir schätzen den Parameter(vektor) β durch

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p'}} (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta) \quad (6)$$

und nennen $\hat{\beta}$ den KQ-Schätzer von β und $\hat{\varepsilon}_i := Y_i - x_i^T \hat{\beta}$ die Residuen.

Existenz und Berechnung vom KQ Schätzer

Der KQ-Schätzer existiert und ist eindeutig, falls $\mathbf{X}^T \mathbf{X}$ invertierbar ist. Dieser lässt sich berechnen als symmetrische Produktsummenmatrix

$$(\mathbf{X}^T \mathbf{X}) \hat{\beta} = \mathbf{X}^T \mathbf{Y} \Leftrightarrow \hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

Durch differenzieren von der Gleichung (2) erhält man $\hat{\beta}$ als Lösung der Normalengleichung

$$\mathbf{Y}^T \hat{\varepsilon} = \hat{\beta}^T \mathbf{X}^T \hat{\varepsilon} = 0 \quad (\text{folgt auch aus L-Proj})$$

Nur bei Modell mit Intercept

$$\mathbf{X}^T \hat{\varepsilon} = 0 \quad \cdot \mathbf{e}^T \hat{\varepsilon} = 0 \Rightarrow \frac{1}{n} \mathbf{e}^T \hat{\varepsilon} = 0 \Rightarrow \hat{\varepsilon} = \mathbf{0}$$

es gilt immer $E(\mathbf{X}^T \varepsilon) = \mathbf{0}$ $E(\mathbf{X}^T \varepsilon) \text{ mit } E(\varepsilon) = \mathbf{0} \Rightarrow \mathbf{0} = \mathbf{0}$

Gauss-Markov-Theorem

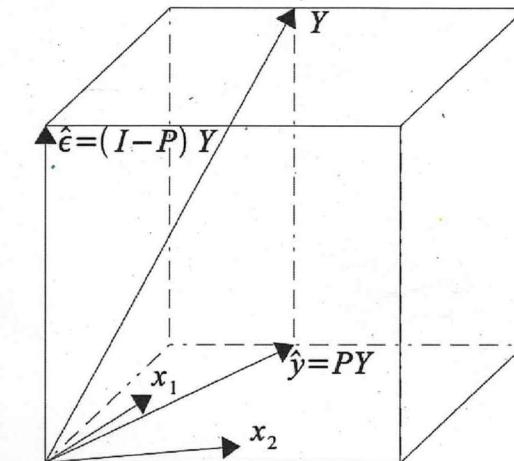
Sei das Modell $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ gegeben mit $E(\varepsilon) = \mathbf{0}$ und $\text{Cov}(\varepsilon) = \sigma^2 \mathbf{I}$. Dann ist der KQ-Schätzer $\hat{\beta}$ der beste lineare erwartungstreue Schätzer (best linear unbiased estimator, BLUE) von β .

Das heißt, dass für jeden anderen linearen erwartungstreuen Schätzer $\tilde{\beta}$ von β gilt: $V(\hat{\beta}) < V(\tilde{\beta})$.

Interpretation der Modellparameter

- **ceteris paribus:** alle anderen x-Variablen bleiben konstant. möglich ist, dass x_i bzw. alle x_j im mult. Modell = 0 sind β_0 kann störfreie Interpretationen haben, wenn es gern ist
- (Theoretische) Interpretation: Steigt x_k um eine Einheit, so steigt Y (ceteris paribus) im Erwartungswert um β_k Einheiten. $\beta_0 = E(Y)$ wenn alle $x_k = 0$
- (Empirische) Interpretation: Steigt x_k um eine Einheit, so steigt Y (ceteris paribus) im Durchschnitt um $\hat{\beta}_k$ Einheiten.
- ! β_k charakterisiert den Einfluss von x_k unter Berücksichtigung der übrigen Variablen (Confounder-Korrektur). Das heißt, dass in einem einfachen linearen Regressionsmodell mit $Y_i = \beta_0 + \beta'_k x_{ik} + \varepsilon_i$ wäre im Allgemeinen $\beta'_k \neq \beta_k$.

Geometrische Interpretation



Die KQ-Schätzung ist eine orthogonale Projektion von \mathbf{Y} auf den von den \mathbf{x} -Vektoren aufgespannten Unterraum. $\text{col}(\mathbf{X})$ ohne Intercept / nach Zentrierung bzw. $\text{col}(\mathbf{X}_1, \mathbf{X}_2)$ mit Intercept

Eigenschaften des KQ-Schätzers

Gegeben dem multiplen linearen Modell, gilt für den KQ-Schätzer $\hat{\beta}$

$$\hat{\beta} \perp \hat{\varepsilon}^2$$

- Erwartungstreue: $E(\hat{\beta}) = \beta$.
! Gilt auch ohne die Annahme $\varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$, solange $E(\varepsilon) = \mathbf{0}$
- $V(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$.
! Gilt auch ohne die Annahme $\varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$, solange $\text{Cov}(\varepsilon) = \sigma^2 \mathbf{I}$
- $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$ $\hat{\beta} \perp \hat{\varepsilon}$ gilt aber, auch $\hat{\beta} \perp \varepsilon$ neu gezeigt, frische Seiten

Hat-Matrix und Residualmatrix

Gegeben dem multiplen linearen Modell mit $\text{rang}(\mathbf{X}) = p'$ gilt

$$\hat{Y} := \underbrace{\mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}}_{\hat{\beta}}$$

orthogonale, von Vektor
Projektion auf $\text{col}(\mathbf{X})$ $P := \underbrace{\mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T}_{n \times n}$ Hat-Matrix
 $P \cdot \mathbf{Y} = \mathbf{Y}$ "P setzt Y Hinter"

$$\hat{\varepsilon} = \mathbf{Y} - \hat{Y} = (\mathbf{I} - \mathbf{P}) \mathbf{Y} \stackrel{!}{=} (\mathbf{I} - \mathbf{P}) \varepsilon$$

$$Q := \mathbf{I} - P \Leftrightarrow \mathbf{I} = (Q + P)$$

P, Q berdes quadr. $n \times n$ Matrizen

P heißt Hat-Matrix und Q heißt Residualmatrix.

Eigenschaften von P und Q

Die Hat-Matrix P und die Residualmatrix Q sind Projektionsmatrizen und zueinander orthogonal: $P \cdot Q = Q \cdot P = \mathbf{0}$

Als orthogonale Projektionsmatrizen sind P, Q beide symmetrisch & idempotent

$$P^T = P \text{ und } P^2 = P \quad \text{doppelte Regression } P \cdot P^T = \mathbf{I}$$

$$Q^T = Q \text{ und } Q^2 = Q \quad P \cdot X = X \Rightarrow Q \cdot X = (I - P) \cdot X = 0$$

$$PQ = QP = \mathbf{0} \quad PQ = \mathbf{0}, \text{ also } P(I - P) = \mathbf{0}$$

Logisch auch: $P \cdot \mathbf{I} = \mathbf{I}$, $P \cdot \mathbf{0} = \mathbf{0}$

$$(PQ) \cdot \mathbf{Y} = P(Q \cdot \mathbf{Y}) = P \cdot \mathbf{0} = \mathbf{0}$$

Regression von Residuen liefert $\hat{\varepsilon} = \mathbf{0}$!!

$$V(\hat{Y}) = \sigma^2 P \quad \text{Var}(\hat{Y}) = \text{Var}(P \cdot \mathbf{Y}) = P \cdot \sigma^2 \cdot P^T = \sigma^2 P^2 = \sigma^2 P$$

$$V(\hat{\varepsilon}) = \sigma^2 Q, \text{ da } \hat{\varepsilon} = Q \cdot \mathbf{Y} \quad \text{Var}(\hat{\varepsilon}) = \text{Var}(Q \cdot \mathbf{Y}) = \dots$$

Schätzer für σ^2

Gegeben dem multiplen linearen Modell, gilt

$$\hat{\sigma}^2 := \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - p'} = \frac{1}{n - p'} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

ist ein erwartungstreuer Schätzer von σ^2 .

! Gilt auch ohne die Annahme $\varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$, solange $E(\varepsilon) = \mathbf{0}$ und $\text{Cov}(\varepsilon) = \sigma^2 \mathbf{I}$

Kapitel 3 - Quadratsummenzerlegung und statistische Inferenz im multiplen linearen Regressionsmodell

Quadratsummenzerlegung

Gegeben sei das multiple lineare Regressionsmodell mit $\text{rang}(X) = p'$. Dann gilt

$$\underbrace{(Y - \bar{Y})^\top(Y - \bar{Y})}_{SST} = \underbrace{(Y - \hat{Y})^\top(Y - \hat{Y})}_{SSE RSS} + \underbrace{(\hat{Y} - \bar{Y})^\top(\hat{Y} - \bar{Y})}_{SSM}$$

- SST(otal): Gesamt-Quadratsumme (korrigiert)
- SSE(ror): Fehler-Quadratsumme
- SSM(odel): Modell-Quadratsumme

Quadratsummenzerlegung ohne β_0

Gegeben sei das multiple lineare Regressionsmodell mit, aber ohne Absolutglied β_0 . Dann gilt

$$\begin{aligned} Y^\top Y &= \underbrace{(Y - \hat{Y})^\top(Y - \hat{Y})}_{SSE} + \underbrace{\hat{Y}^\top \hat{Y}}_{SSM^*} = \hat{e}^\top \hat{e} + \hat{\beta}^\top \hat{\beta} \\ SST^* &= \underbrace{Y^\top Y}_{\text{Eigentlich von } P_Q} = \hat{Y}^\top Q \hat{Y} + \hat{\beta}^\top P \hat{Y} = \hat{Y}^\top Q^\top Q \hat{Y} + \hat{\beta}^\top P^\top P \hat{Y} = (\hat{Q}\hat{Y})^\top Q \hat{Y} + (\hat{\beta}\hat{Y})^\top P \hat{Y} \\ SST^*: &\text{ Gesamt-Quadratsumme (nicht korrigiert)} \\ SSE: &\text{ Fehler-Quadratsumme (wie zuvor)} \\ SSM^*: &\text{ Modell-Quadratsumme (nicht korrigiert)} \\ E(SST^*) &= E(Y^\top Y) = E[(X\beta + \varepsilon)^\top(X\beta + \varepsilon)] = E[(X^\top X\beta + \varepsilon^\top)(X\beta + \varepsilon)] = E[X^\top X\beta X\beta^\top + E(\varepsilon^\top)\varepsilon] = E(\varepsilon^\top)\varepsilon = 0 \\ E(SSE) &= E(Y^\top Y) - E(SST^*) = E[(X\beta + \varepsilon)^\top(X\beta + \varepsilon)] - E[(X^\top X\beta + \varepsilon^\top)(X\beta + \varepsilon)] = E[(X^\top X\beta X\beta^\top + E(\varepsilon^\top)\varepsilon) - E(\varepsilon^\top)\varepsilon] = E(\varepsilon^\top)\varepsilon = 0 \end{aligned}$$

Erwartungswerte der Quadratsummen

Gegeben sei das multiple lineare Regressionsmodell mit den üblichen Annahmen. Wir definieren

$$e = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \quad \text{P.e. Qe symmetrisch \& idempotent genau wie P, Q} \quad \text{und } P_e = e(e^\top e)^{-1} e^\top \quad \text{und } Q_e = I - P_e.$$

Projektion auf den von e aufgespannten 1D-Raum

also Regression auf Konstante $E(Y) = \mu_0$
mit $\hat{V} = \frac{1}{n} \sum_i V_i$ (dann gleich $\text{spalte } \hat{\beta}$)

Dann gilt für alle n -dim. Vektoren (!) \tilde{V} : $P_e V = \tilde{V}^\top e$, $Q_e V = V - \tilde{V}^\top e$.

P_e : MW bilden Q_e : Mittelwertbereinigungs-Operator, Zentrierung

$$P_e Y = \bar{Y} = P_e \tilde{Y} \quad \text{und} \quad Q_e Y = Y - \bar{Y}, \quad Q_e \tilde{e} = \tilde{e} (\tilde{e}^\top \tilde{e} = 0)$$

$$E(SST^*) = \sigma^2 n + \beta^\top X^\top X \beta \quad \text{P.e. } \tilde{e} = 0$$

$$E(SST) = \sigma^2 (n-1) + \beta^\top (Q_e X)^\top (Q_e X) \beta$$

$$E(SSE) = \sigma^2 (n-p') \sigma^2 \cdot \text{trace}(I-H)$$

$$E(SSM^*) = \sigma^2 p' + \beta^\top X^\top X \beta \quad \text{Weil } Q_e X = X - \bar{X} \text{ folgt, dass 1. Spalte von } Q_e X \text{ (Intercept) } = 0 \text{ ist}$$

$$E(SSM) = \sigma^2 (p'-1) + \beta^\top (Q_e X)^\top (Q_e X) \beta$$

$$\sigma^2 p$$

Wir können diese Eigenschaften zur Konstruktion von Tests verwenden. Es gilt nämlich unter anderem $\beta = 0 \implies E(SST^*) = \sigma^2 n$ $SSM \gg E(SSM) \Rightarrow P(\text{mindestens ein } \beta_k \neq 0) \rightarrow 1$

$$\beta_1 = \dots = \beta_p = 0 \implies E(SSM) = \sigma^2 (p'-1)$$

(ohne $\beta_0 = 0$, das wäre deterministische Regression ohne Fehler, $\tilde{e} = 0$)

Mittlere Quadratsummen

Wir definieren entsprechend der Zahl der Freiheitsgrade die **mittleren Quadratsummen** als

brauchen wir für
lineare Hypothesen
und Modellvergleiche
(F-Tests).

Nur mittlere Quadratsummen
sind untereinander sowie
zwischen Modellen
vergleichbar durch
FG-Koeffizient!

$$\text{MSE} = \frac{SSE}{n-p'} = \hat{\sigma}^2$$

$$\text{MSM} = \frac{SSM}{p'-1}$$

$$\text{MST} = \frac{SST}{n-1} \neq \text{MSE} + \text{MSM}$$

$$\text{MSM}^* = \frac{SSM^*}{p'}$$

$$\text{MST}^* = \frac{SST^*}{n}$$

R^2

Gegeben sei das multiple lineare Regressionsmodell mit allen Annahmen. Dann definieren wir das **Bestimmtheitsmaß R^2** als

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST} = r_{YY}^2 \in [0, 1]$$

wobei r_{YY} der Korrelationskoeffizient zwischen \mathbf{Y} und $\hat{\mathbf{Y}}$ ist.

Wir interpretieren R^2 als den Anteil der Varianz von \mathbf{Y} , die durch das Modell erklärt wird. Ein hohes R^2 deutet darauf hin, dass unser Modell gut nutzen können, um \mathbf{Y} zu erklären. R^2 steigt mit steigender Anzahl an Kovariablen, auch wenn diese kaum/keine Erklärungskraft haben. Es ist daher nicht sinnvoll, R^2 zwischen Modellen zu vergleichen, die unterschiedlich viele Kovariablen haben. Hierfür nutzen wir das **adjustierte Bestimmtheitsmaß**

$$\begin{aligned} R_{\text{adj}}^2 &= \frac{MSM}{MST} = 1 - \frac{MSE}{MST} = 1 - \frac{SSE/(n-1)}{SST/(n-p')} \\ &= 1 - \frac{n-1}{n-p'} (1 - R^2) \end{aligned}$$

Art Penalisierung von zusätzl. Kovariablen

Für $n \gg p'$ gilt $R_{\text{adj}}^2 \approx R^2$.

Bei einem Modell ohne Absolutglied ist R^2 nach obiger Definition nicht sinnvoll, da es dann auch negative Werte annehmen kann. Das kommt daher, dass die Zerlegung $SST = SSE + SSM$ nicht mehr gilt. Stattdessen ist es sinnvoll, R^2 als $\frac{SSM^*}{SST^*}$

Multivariate Normalverteilung

Eine Zufallsvariable $Z \in \mathbb{R}^n$ heißt **multivariat normalverteilt** mit Erwartungswert $\mu \in \mathbb{R}^n$ und positiv definiter Kovarianzmatrix $\Sigma \in \mathbb{R}^{n \times n}$, wenn ihre Dichte gegeben ist durch

$$f(z) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(z - \mu)^\top \Sigma^{-1}(z - \mu)\right).$$

Wir schreiben $Z \sim \mathcal{N}_n(\mu, \Sigma)$.

Eigenschaften von $\mathcal{N}_n(\mu, \Sigma)$

Sei $Z \sim \mathcal{N}_n(\mu, \Sigma)$ und $A \in \mathbb{R}^{m \times n}$ mit $\text{rang}(A) = m$. Dann gilt

1. $\mathbb{E}(Z) = \mu$
2. $\text{V}(Z) = \Sigma$
3. $AZ \sim \mathcal{N}_m(A\mu, A\Sigma A^\top)$
4. Es existiert eine orthogonale Matrix $T \in \mathbb{R}^{n \times n}$ mit $T\Sigma T^\top = \text{diag}(\lambda_1, \dots, \lambda_n)$, so dass $TZ \sim \mathcal{N}_n(T\mu, \text{diag}(\lambda_1, \dots, \lambda_n))$

Chi-Quadrat Verteilung

Sei $Z \sim \mathcal{N}_n(\mu, I)$, so heißt $W = Z^\top Z = \sum_{i=1}^n Z_i^2$ (nicht-zentral) **Chi-Quadrat-verteilt** und wir schreiben

$$W \sim \chi^2(n, \delta).$$

Wir nennen n die **Zahl der Freiheitsgrade** und $\delta = \mu^\top \mu$ den **Nicht-Zentralitätsparameter**. Es gilt ($\delta = 0$ ergibt zentrale $\chi^2(n)$ -Verteilung)

$$\mathbb{E}(W) = n + \delta$$

$$\text{V}(W) = 2n + 4\delta$$

Merk: $R^2 < 0$ bedeutet Modell performt schlechter als MW-Vorhersage $\hat{Y} = \bar{Y}$

t-Verteilung

Seien $Z \sim \mathcal{N}(\delta, 1)$ und $W \sim \chi^2(n, 0)$ unabhängig. Dann heißt $T = \frac{Z}{\sqrt{\frac{W}{n}}}$ (nicht-zentral) **t-verteilt** mit n **Freiheitsgraden** und **Nicht-Zentralitätsparameter** δ und wir schreiben

$$T \sim t(n, \delta).$$

Es gilt

V(T) existiert nicht!

$$\mathbb{E}(T) = \delta \sqrt{\frac{n}{2} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})}} \text{ für } n > 1$$

F-Verteilung

Sei $W_1 \sim \chi^2(n_1, \delta)$ und $W_2 \sim \chi^2(n_2, 0)$ unabhängig. Dann heißt $X = \frac{W_1/n_1}{W_2/n_2}$ (nicht-zentral) **F-verteil** mit n_1 und n_2 **Freiheitsgraden** und **Nicht-Zentralitätsparameter** δ und wir schreiben
 $\delta = 0$: zentrale F-Verteilung $F(n_1, n_2)$

$$X \sim F(n_1, n_2, \delta). \quad \begin{matrix} \text{linksseitige} \\ \text{rechtsseitige Verteilung} \end{matrix}$$

Es gilt

$$\mathbb{E}(X) = \frac{n_2 + \frac{n_2 \delta}{n_1}}{n_2 - 2} \text{ für } n_2 > 2$$

Satz von Cochran

Unabhängigkeit von Quadratsummen der orthog. Projektionen auf X-Ebene

- $Z \sim \mathcal{N}_n(\mu, \Sigma)$, $\dim(Z) = n$
- $A \in \mathbb{R}^{n \times n}$ mit $\text{rang}(A) = r$ und $A^2 = A$,
- $B \in \mathbb{R}^{n \times n}$ mit $B^2 = B$ und $B^\top = B$,
- $C \in \mathbb{R}^{m \times n}$.

dann gilt

$$Z^\top AZ \sim \chi^2(r, \mu^\top A\mu)$$

$CA = 0 \Rightarrow CZ$ und $Z^\top AZ$ sind unabhängig.

$AB = 0 \Rightarrow Z^\top AZ$ und $Z^\top BZ$ sind unabhängig.

Verteilung des KQ-Schätzers

Gegeben sei das multiple lineare Regressionsmodell mit $\text{rang}(\mathbf{X}) = p'$ und den üblichen Annahmen über ε . Dann gilt für den KQ-Schätzer $\hat{\beta}$:

also auch Erwartungstreue: $\mathbb{E}(\hat{\beta}) = \beta$

$$\hat{\beta} \sim \mathcal{N}_p(\beta, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$$

$$\hat{\Sigma}_{\hat{\beta}} := \hat{\sigma}^2(\mathbf{X}^\top \mathbf{X})^{-1}$$

$$(n-p') \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-p')$$

$\hat{\sigma}^2$ und $\hat{\beta}$ sind unabhängig.

$$\hat{\sigma}_{\hat{\beta}_k}^2 := (\hat{\Sigma}_{\hat{\beta}})_{kk}$$

$$\frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}_{\hat{\beta}_k}^2}} \sim t(n-p', 0) \quad \begin{matrix} \text{nur } \hat{\beta}_k \text{ V-Vert ist MV} \\ \text{einzelne } \hat{\beta}_k \text{ sind t-verteil,} \\ \text{wobei t-Verteilung ähnlich wie} \\ \text{MV (und für } n \rightarrow \infty \text{ t } \approx \text{MV)} \end{matrix}$$

Um exakte Tests durchzuführen, ist die Normalverteilungsannahme für ε notwendig. Jedoch gelten einige Eigenschaften auch approximativ ohne diese Annahme. Nehmen wir stattdessen an, dass gilt

$$\lim_{n \rightarrow \infty} \frac{1}{n} \mathbf{X}^\top \mathbf{X} = V, \quad V \text{ positive definit.} \quad \begin{matrix} \text{konvergiert} \\ \text{für } n \rightarrow \infty \text{ f.s. gegen } \mathbf{B}_0 \mathbf{\sigma}^2 \end{matrix}$$

Dann gilt weiterhin, dass $\hat{\beta}$ und $\hat{\sigma}^2$ consistent sind und

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}_p(\mathbf{0}, \sigma^2 V^{-1}).$$

Daraus folgt die für die Praxis essenzielle Eigenschaft

$$\hat{\beta} \stackrel{a}{\sim} \mathcal{N}_p(\beta, \hat{\sigma}^2 \frac{(\mathbf{X}^\top \mathbf{X})^{-1}}{n}) \text{ für großes } n.$$

\Rightarrow auch ohne MV der Fehler können wir Inferenz betreiben, wenn n groß genug!

Overall-Test

Gegeben sei das multiple lineare Regressionsmodell mit $\text{rang}(\mathbf{X}) = p'$. Dann gilt für die mittleren Quadratsummen $SSM \sim \chi^2(p'-1, \delta - \beta^\top \dots \beta^\top / \sigma^2)$, $SSE \sim \chi^2(n-p', 0)$

$$F_0 = \frac{MSM}{MSE} \sim F(p'-1, n-p', \frac{\beta^\top (\mathbf{Q}_e \mathbf{X})^\top (\mathbf{Q}_e \mathbf{X}) \beta}{\sigma^2})$$

Wir können damit den **Overall-Test** durchführen, um die Hypothese allgemeine Form $A\beta = 0$ mit $A = [\mathbf{I}_p, \mathbf{I}_{p'}]$

$$H_0^O : \beta_1 = \dots = \beta_{p'} = 0 \quad \begin{matrix} \text{1. Spalte Intercept egal} \end{matrix}$$

bzw. $R^2 = 0$ zu testen. Wir lehnen H_0^O ab, wenn $F_0 > F_{1-\alpha}(p'-1, n-p')$.

Allgemeine lineare Hypothese

Es sollen Hypothesen der Form $H_0 : A\beta = c$ getestet werden, wobei $A \in \mathbb{R}^{a \times p'}$ mit $\text{rang}(A) = a$ und $c \in \mathbb{R}^a$.

Wir definieren

$$\text{alternativ } SSH = \hat{\varepsilon}^\top \hat{\varepsilon} - \hat{\varepsilon}^\top \hat{\varepsilon}$$

$$SSH := (\mathbf{A}\hat{\beta} - c)^\top (\mathbf{A}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{A}^\top)^{-1} (\mathbf{A}\hat{\beta} - c)$$

$$MSH := \frac{SSH}{a}$$

$$\delta_{SSH} := (\mathbf{A}\beta - c)^\top (\mathbf{A}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{A}^\top)^{-1} (\mathbf{A}\beta - c).$$

SSH beschreibt die Quadratsumme der Abweichung von der Hypothese $A\beta = c$.

Es gilt

$$\frac{SSH}{\sigma^2} \sim \chi^2(a, \frac{\delta_{SSH}}{\sigma^2}),$$

$$TF = \frac{MSH}{MSE} \sim F(a, n-p', \frac{\delta_{SSH}}{\sigma^2}).$$

Damit können wir nun die Hypothese $H_0 : A\beta = c$ testen. Wir lehnen H_0 ab, wenn

$$\frac{MSH}{MSE} > F_{1-\alpha}(a, n-p').$$

Dieses Vorgehen können wir als Wald-Test identifizieren und in diesem Fall entspricht dieser einem Likelihood-Quotienten-Test, ist also optimal.

Der Test vergleicht intuitiv den SSE des Modells mit dem SSE des Modells unter $H_0 : A\beta = c$.

Für $n \rightarrow \infty$ gilt $\frac{MSH}{MSE} \rightarrow \frac{SSH}{\sigma^2}$, d.h. im Allgemeinen ist die F-Verteilung asymptotisch Chi-Quadrat-verteil.

Partielle Quadratsummen

Gegeben sei das multiple lineare Regressionsmodell mit $\text{rang}(\mathbf{X}) = p'$. Die zu der Hypothese $H_0 : \beta_k = 0$ gehörende Quadratsumme bzgl. des Gesamtmodells heißt **partielle Quadratsumme** und wird definiert als

$$R(\beta_k | \beta_1, \dots, \beta_{k-1}, \beta_{k+1}, \dots, \beta_{p'}) = SSE(M_{-k}) - SSE$$

wobei M_{-k} das Modell mit $\beta_k = 0$ ist.