

Quadratsummenzerlegung im einfachen linearen Modell

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n \frac{\hat{\epsilon}_i^2}{n-1} = \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{SST(alt)} + \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SST(Mittel)}$$

Beweis: $\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n ((y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}))^2$

$$= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y})$$

$$= \sum_{i=1}^n \hat{\epsilon}_i^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \hat{\epsilon}_0^2 + \hat{\epsilon}_1^2 \sum_{i=1}^n x_i - \bar{y} \sum_{i=1}^n \hat{\epsilon}_i$$

1 Normalgleichung

$$\sum \hat{\epsilon}_i = 0, \sum \hat{\epsilon}_i x_i = 0$$

Freiheitsgrade der Quadratsummen = Anzahl der frei bestimmbar Summanden der obigen Quadratsummen

SST: $\sum (y_i - \bar{y})^2$ $df = n - 1$. Wobei einen Freiheitsgrad durch Schätzung von \bar{y} (genauer gesagt muss \bar{y} geschätzt werden, dass $\sum (y_i - \bar{y}) = 0$) $n - 1 = (n - 2) + 1$

SSE: $\sum (y_i - \hat{y}_i)^2$ Dies minimieren wir bei KQ-Schätzung von $\beta_0, \beta_1 \Rightarrow df = n - 2$, da wir zwei Parameter der KQ schätzen (zwei Restriktion durch Normalgleichungen)

SSM: $\sum (\hat{y}_i - \bar{y})^2 = \sum (\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{y})^2 = \sum (\hat{\beta}_1 (x_i - \bar{x}))^2$ $df = 1$, da es nur einen Regressor gibt. 1 Fz verbraucht für \bar{y} , (n-2) Fz verbraucht für $\hat{\beta}_1$

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ durch Wählen von einem y -Wert liegt $\hat{\beta}_1$ fest

Anpassungsgrade "fit"

Bestimmtheitsgrad $R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST}$ Durch x erklärter Anteil der Varianz von y

(bzw. schlechteres bleibt es losband)

$R^2 = \frac{SSM}{SST} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\sum_{i=1}^n (\hat{\beta}_1 (x_i - \bar{x}))^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$ R^2 ist ein Maß für die Varianz von y, die durch x erklärt wird.

Jede Streuung der y_i umso höher R^2 , SSE wird immer gleich bleiben und so steigen SSM u. R^2 es ist also Vorhersage Regressoren mit großer Varianz zu wählen (gibt dann Var($\hat{\beta}_1$) = $\frac{\sigma^2}{n \sum x_i^2}$)

$R^2 = \frac{SSM}{SST} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\sum_{i=1}^n (\hat{\beta}_1 (x_i - \bar{x}))^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\hat{\beta}_1^2 \cdot n \cdot S_x^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\hat{\beta}_1^2 \cdot n \cdot S_x^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\hat{\beta}_1^2 \cdot n \cdot S_x^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Nach Schätzung können wir $\hat{\beta}_1$ als feste Zahl betrachten, also aus Reihe ziehen

Für ELMS und ML-Modell gibt es diese Zerlegung gar nicht bzw. schwer allgemein zu definieren

Quadratsummenzerlegung im multiplen linearen Modell

Freiheitsgrade der Quadratsummen

$(y - \bar{y})^T (y - \bar{y}) = (y - \hat{y})^T (y - \hat{y}) + (\hat{y} - \bar{y})^T (\hat{y} - \bar{y})$

SST = $\sum_{i=1}^n (y_i - \bar{y})^2$ SSE = $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ SSM = $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

Geometrische Intuition: Quadratsummen als Längen im Raum im Sinne der euklidischen 2-Norm, Zerlegung folgt aus Satz 4. Pythagoras da $(y - \bar{y}) \perp (\hat{y} - \bar{y})$

SST = $\|y - \bar{y}\|_2^2$ misst Gesamtstreuung von y zu seinem MW, völlig unabh. von Regressionsmodell (braucht nur Beob. und \bar{y})

SSE = $\|y - \hat{y}\|_2^2$ ist Länge der orthogonalen Residualkomponente $\hat{\epsilon}$, also das was die Regression nicht "erklären kann" (gibt auch gewollt)

SSM = $\|\hat{y} - \bar{y}\|_2^2$ misst Länge der orth. Projektion von $(y - \bar{y})$ auf $col(C_1, X_1)$ ohne Intercept nur: $\|y - \bar{y}\|_2^2 = \|y - \hat{y}\|_2^2 + \|\hat{y} - \bar{y}\|_2^2$

Entsprechend R^2 : Effektiv 1 Projektion auf $col(C_1, X_1)$ (bzw. \hat{y}) etwas adj oder ist es rein zufällig? Nutzen des nicht im Intercept-Modell, weil mit dann nicht Verfallen von y zerlegen

Hohes R^2 bedeutet: Gute Erklärungskraft des Modells (bezüglich Varianz von y, SST) also im Vergleich mit Vorhersage nur mit Mittelwert von y!

R^2 hoch \Rightarrow Modell gut, R^2 niedrig \Rightarrow Modell nutzlos

gibt nicht an

R^2 kann "tauschen" vergroßert werden, indem man ganz viele Regressoren ins Modell aufnimmt. Aber ist das die zusätzliche Komplexität wert?!

(gute Idee hinter R^2_{adj} ist Penalisierung von mehr Parametern, evtl. besser)

Merke: $R^2 < 0 \Rightarrow$ Modell perform schlechter als einfache Vorhersage mit Mittelwert von y

$R_2 > 0$ geht nur, wenn $SSE < SST$ dann $\hat{y} = \bar{y}$ und $SST = SSE \Rightarrow R^2 = 1 - 1 = 0$

Wie kann R^2 negativ werden? In Modell ohne Intercept (da ist R^2 auch kein sinnvolles Maß)

garantiert mindestens besser als $\hat{y} = \bar{y}$ denn das wäre schlechterer Schätzer von SSE -Minimierung, also $R^2_{min} \geq 0$ (aber gilt nur für Trainings-Datensatz!)

ii) Modell mit Intercept und evtl. auf Fremden Testdaten, auf denen es sehr schlecht abschwächt evtl. auch aufgrund von Overfitting durch R^2 -Optimierung

$R^2 < 0$ dann möglich, wenn lineare Beziehung im Test-Satz schwach ist oder sich im Test-Satz zu Trainingsmodell sogar umkehrt, sodass $SSE_{test} > SSE_{train}$

Kann schnell passieren bei ML bzw. allgemein Extrapolation bei Trend-Vorhersagen, wobei Trend im Testdatensatz umkehrt

\Rightarrow Neben Anpassungsgrade R^2 gibt es noch Prognosegrade RMSE zur Modell-Evaluierung und Vergleich von Qualität verschiedener Modelle

Maßzahl für durchschnittl. Abweichung von Prognosen $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$ sollte immer auf Basis von Testdaten bestimmt werden, da es in Modell-Schätzung einbezogen wurden

Wurde von mittleren quadr. Fehler